

## Semi-supervised learning with GAN – part 2

讨论文章：

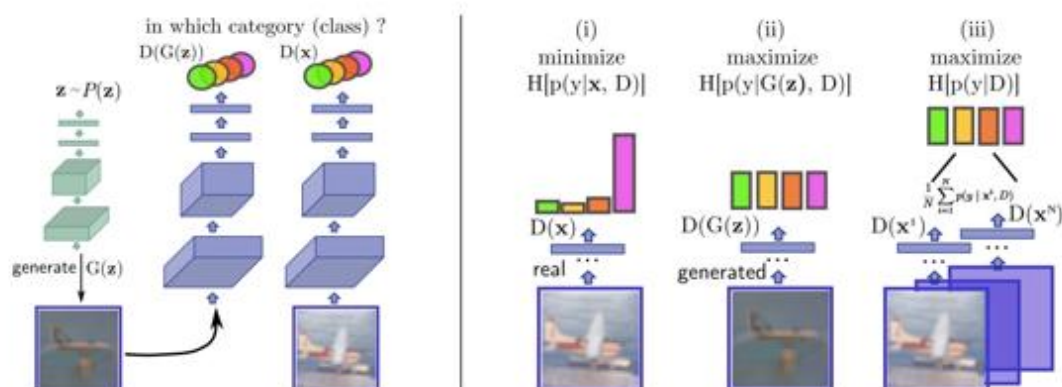
- Unsupervised and Semi-supervised Learning with Categorical Generative Adversarial Networks (arxiv id: 1511.06390, ICLR 2016); a.k.a **CatGAN**
- Triple Generative Adversarial Nets (arxiv id: 1703.02291); a.k.a **TripleGAN**

### 一、CatGAN

本场讨论由毛豆大佬（郑华滨）主导，分别往深向和纵向展开，讨论水平比较高，能够加入讨论的人不多。这里的总结按照毛豆大佬的思路展开。

#### 🌈 深向讨论

- ✓ **CatGAN** 既可以做无监督，也可以做半监督。
- ✓ **判别器**：利用样本标签，希望它对真样本正确且明确地分类，正确类的概率要高；对假样本模糊分类，每一类的概率都要低。体现在概率分布上，真样本是尖峰分布（而且尖峰得在正确类上），假样本是平坦分布。



- ✓ **生成器**：希望能够在判别器那边获得一个尖峰，随便任何一个尖峰都可以。
- ✓ **Loss**：只要是用互信息。对于判别器，它的目标是最大化真实无标签样本的（样本与标签之间的）互信息，对于有标签样本，它则优化交叉熵，对于生成样本，它要最小化（样本与标签之间的）条件熵以达成平坦分布；对于生成器，它的目标是最大化生成样本的互信息（注意这里的标签是未指定的，因此随便一个尖峰都可以）。
- ✓ **一种可能的解释**：对 CatGAN 的可行性，猫豆大佬指出，可以从标签传播（label propagation）的角度进行解释。
  - 标签传播是半监督学习的经典范式之一，想法是从少量有标注样本出发，不断地往它们周边临近的样本“传染”自己的标签，慢慢地往外传播，直到所有的无标签样本都被传染到某一个标签。如果某个无标签样本距离有标签样本  $a$  很近，那它也很可能被“感染”上  $a$  的标签。
  - 单从判别器的角度来说，如果现在有一个跟 labelled sample A 非常临近的 unlabelled sample B，那么 B 在判别器那边应该会获得一个相对不那么尖峰、但最高峰类别仍然正确的概率分布。此时我们要求它尖峰更尖，那只会强化它原来的正确概率。在这个过程中，样本 A 的标签就稍微“传染”了临近的样本 B，使得样本 B 对于正确的类别更加“确信”。
  - 生成器在标签传播意义下的作用：g 建立了一道“隔离带”，阻止 label 跨界传染。

- 标签传播与文中提出的 half shot learning 有相似之处。
  - ◆ Half shot learning: 比如我现在要做 10 类的分类, 先按照非监督的方法聚成 20 簇, 然后再人工将每个簇对应到一个类。
  - ◆ 标签传播是半监督的, jointly train; half shot learning 属于无监督的, assign 标签和聚类是分开的, 它不对应到真实的类别上也能自成一体。
- ✓ CatGAN 跟 Good SSL requires bad GAN 那篇有很多联系哦! 后者从理论上做了一些分析, 很有趣, 期待下一次 SSL 的讨论吧! 提前准备一下, 你也能参与进来。

## ✚ 纵向延伸

从判别器对真实有标签样本要求尖峰分布, 对生成样本要求平坦分布的角度, 可以将 CatGAN 与 CAN (Creative Adversarial Networks Generating “Art” by Learning About Styles and Deviating from Style Norms) 做一个对比。(PS: 要看懂下面的讨论, 请先研究 CatGAN 和 CAN 的 loss 设计。)

- ✓ CAN
  - CAN 想要生成艺术作品, 但是又希望有创新性, 这是 motivation。
  - CAN 里面说的风格就是 label, 就是 CatGAN 中的 category。
  - 1. 让判别器做两个任务——区分真假和区分图像的艺术风格, 看是巴洛克风格还是印象派之类的。
  - 2. 让生成器的输出在判别器那边获得真概率, 同时获得平坦的多类概率分布。
  - CAN 这样要求的原因是: 既要像真的, 又要无法被归为哪一类艺术风格, 既然无法归类, 那就说明是创造了一种新的艺术风格。
- ✓ CAN 的生成器是想要获得平坦的多类概率分布, CatGAN 的生成器想要获得尖峰分布
- ✓ 也正因此, CAN 产生的图像风格有点奇怪。对此, 猫豆大佬是这样解释的: **艺术家的事情, 你等凡人不懂。吃瓜群众表示还是继续吃瓜好了。**




## 二、TripleGAN

- ✓ TripleGAN 涉及三方, 判别器、生成器和分类器。其中, 判别器和生成器有对抗; 判别器和分类器 (在训练前期) 有对抗; 生成器和分类器有一点的协助作用。可以从斗地主

的角度来看，判别器是地主，生成器和分类器是农名。

- ✓ TripleGAN 还可以这么理解：拆掉分类器，它就是一个 CGAN。拆掉生成器，它就是一个半监督的 GAN。分类器和生成器有协助作用。判别器扮演统筹的角色。



- ✓ **判别器**：判断样本与标签是否匹配。D 对于 C 来说，作用就是评估分类性能。
- ✓ **生成器**：生成特定类别的图像，使得它尽可能地像真实样本。
- ✓ **分类器**：对带标签的真样本要做监督学习（优化交叉熵），对没有标签的真样本要预测 label，然后送给 D 去判断分类好不好。对于生成样本（带标签），当做带标签的真样本做监督学习。实际上分类器只负责监督学习。对于没有标签的样本，它预测 label 以后就把锅甩给判别器了。
- ✓ 分类器把锅甩给判别器并不是一件简单的事，反向传播的时候，梯度无法直接从 label 回传给分类器，因此需要 reinforce algo。此外，作者还提出了另一种解决方案，增加 confidence loss 和 consistency loss。

Since properly leveraging unlabeled data is key to success in SSL, it is necessary to regularize  $C$  heuristically as in many existing methods [23, 26, 13, 15] to make more accurate predictions. We consider two alternative losses on the unlabeled data. Confidence loss [26] minimizes the conditional entropy of  $p_c(y|x)$  and the cross entropy between  $p(y)$  and  $p_c(y)$ , weighted by a hyperparameter  $\alpha_B$ , as  $\mathcal{R}_U = H_{p_c}(y|x) + \alpha_B E_p[-\log p_c(y)]$ , which encourages  $C$  to make predictions confidently and be balanced on unlabeled data. Consistency loss [13] penalizes the network if it predicts the same unlabeled data inconsistently given different noise  $\epsilon$ , e.g., dropout masks, as  $\mathcal{R}_U = E_{x \sim p(x)} \|p_c(y|x, \epsilon) - p_c(y|x, \epsilon')\|^2$ , where  $\|\cdot\|^2$  is the square of the  $l_2$ -norm. We use the confidence loss by default except on the CIFAR10 dataset (See details in Sec. 5).

Another consideration is to compute the gradients of  $E_{x \sim p(x), y \sim p_c(y|x)} [\log(1 - D(x, y))]$  with respect to the parameters  $\theta_c$  in  $C$ , which involves summation over the discrete random variable  $y$ . Because directly integrating out  $y$  is time-consuming, we use a variant of the REINFORCE algorithm [29], in which the gradients should be  $E_{x \sim p(x)} E_{y \sim p_c(y|x)} [\nabla_{\theta_c} \log p_c(y|x) \log(1 - D(x, y))]$ . In our experiment, we find the best strategy is to use most probable  $y$  instead of sampling one to approximate the expectation over  $y$ . The bias is small as the prediction of  $C$  is rather confident typically.

- ✓ 生成器对  $p(x|y)$  进行建模，而分类器则对  $p(y|x)$  建模。两者恰好构成对偶！我们来看一下是否真的是对偶学习，对偶学习要求两个方向的建模要得到一致的  $p(x, y)$ ，也就是  $p(x)p(y|x) \approx p(y)p(x|y)$ 。而这个目标实际上是通过统筹者判别器来达成的，判别器恰好是对  $p(x, y)$  进行建模，它接收的样本来源包括：生成器、分类器和带标签的真实样本。一个成功的判别器将使得生成器方向建模的  $p(x, y)$  和分类器方向建模的  $p(x, y)$  达到一致。这是很漂亮的对偶思想！（PS：原来的讨论说不是完整的对偶思想是不对的，在此纠正！）